

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources

Comment minimiser le temps d'exécution de requêtes SQL itérées ?

Antoine Bertin–Paillette

2026

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources

1 But du TIPE

2 Réalisation

3 Optimisations mémoire

4 Conclusion

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources

Nous avons choisi de travailler sur les données de wikipedia

- Des données de pages: titre, contenu, thème, modifications
- Des données d'utilisateur: nom, date d'inscription, nombre de modification
- Des révisions de pages

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations
mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources

Extrait du jeu de données				
	id	ns	title	revision_id
	3	0	Antoine Meillet	230038204
	10	0	Algorithmique	226806957
	15	0	Autriche	229636050
	18	0	Arsène Lupin	230120442
	23	0	Afghanistan	230208941
	27	0	Ada (langage)	226996025
	35	0	Alpes-Maritimes	229772008
	42	0	Argentine	230240365
	44	0	Akira Kurosawa	228584801

Exemple de données de révision				
	id	parent_id	timestamp	contributor_id
	230038204	226458976	1761327915	316223
	226672222	216521656	1750499141	5256901
	228034381	228034155	1754898945	1430140

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources

Requêtes typiques

- Classement des utilisateurs les plus actifs par catégorie
- Utilisateurs experts d'une catégorie
- Pages les plus modifiées par catégorie

Utilisations des résultats

- Récolter et afficher des statistiques utilisateur
- Trier, comparer, sélectionner
- Recommander / rechercher des pages selon des critères

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources

1. Classement des utilisateurs les plus actifs par catégorie

```
1 SELECT c.category_name ,
2         u.username ,
3         COUNT(*) AS edits
4 FROM revisions r
5 JOIN users AS u ON r.user_id = u.user_id
6 JOIN pages AS p ON r.page_id = p.page_id
7 JOIN categories c ON p.category_id = c.category_id
8 GROUP BY c.category_name, u.username
9 ORDER BY c.category_name, edits DESC;
```

2. Pages les plus modifiées par catégorie

```
1 SELECT c.category_name ,
2         p.title ,
3         COUNT(*) AS revisions
4 FROM revisions r
5 JOIN pages AS p ON r.page_id = p.page_id
6 JOIN categories AS c ON p.category_id = c.
   category_id
7 GROUP BY c.category_name, p.title
8 ORDER BY revisions DESC;
```

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources




Figure: Notre objectif est de comparer avec ce genre de graphique notre implémentation et ce qui a déjà été fait.

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources

Ce que nous avons implémenté

- Une BDD fonctionnelle pour la plupart des requêtes
- Des optimisations du plan
- Tester un grand nombre de requêtes et enregistrer les temps
- Les optimisations mémoire
- Comparer avec des implémentation existentes
- Améliorer et optimiser certaines parties imparfaite de l'implémentation

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources

Orientée lignes

- Stockage par enregistrement complet
- Efficace pour SELECT *
- Lit des colonnes inutiles pour les agrégations

Exemple (PostgreSQL, MySQL)

id	name	score
id	name	score
id	name	score

Orientée colonnes

- Stockage par attribut
- Meilleure compression
- Très efficace pour les agrégations analytiques

Exemple (MonetDB, C-Store)

id	name	score
----	------	-------

Source : Abadi et al., *Column-Stores vs. Row-Stores* (SIGMOD 2008)

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations
mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données


Conclusion

Conclusion

Nos ressources

Temps d'exécution normalisés (base ligne = 100)

Requêtes analytiques typiques : SUM, GROUP BY, jointures.



Sources : Abadi et al., *Column-Stores vs. Row-Stores* (SIGMOD 2008) ; *The Design and Implementation of Modern Column-Oriented Database Systems* (2013).

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations
mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources

Index sur page_id

page_id	pointeur
3	→ ligne 1
10	→ ligne 2
15	→ ligne 3
18	→ ligne 4
23	→ ligne 5
27	→ ligne 6
35	→ ligne 7
⋮	⋮

Table pages (Wikipédia)

page_id	title	revision_id
3	Antoine Meillet	230038204
10	Algorithmique	226806957
15	Autriche	229636050
18	Arsène Lupin	230120442
23	Afghanistan	230208941
27	Ada (langage)	226996025
35	Alpes-Maritimes	229772008
⋮	⋮	⋮

Lignes surlignées = résultat de la requête.

```
SELECT title FROM pages WHERE page_id BETWEEN 15 AND 23
```

Sans index : scan de toute la table. Avec index : accès direct aux 3 lignes surlignées.

Gain en lecture

$\mathcal{O}(n) \rightarrow \mathcal{O}(\log n)$

Coût en écriture

Rééquilibrage à chaque
insertion

Coût mémoire

Structure auxiliaire
stockée

Données : dump Wikipédia français — Silberschatz et al., *Database System Concepts*.

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations mémoire

Paradigme ligne
VS colonne


Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources



Principe

- Structure équilibrée d'indexation
- Nœuds internes : navigation
- Feuilles : clés + pointeurs

Sans index

Parcours complet de la
table
 $\Rightarrow \mathcal{O}(n)$ lectures

Avec index B+

Navigation dans l'arbre
 $\Rightarrow \mathcal{O}(\log n)$ lectures

Observation

Réduit fortement le
coût des
recherches, mais
ralentit les
insertions : l'arbre
doit rester équilibré
après chaque
écriture.

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données


Conclusion

Conclusion

Nos ressources

Temps d'exécution normalisés (base ligne = 100)

Requêtes analytiques typiques : SUM, GROUP BY, jointures.



Sources : Abadi et al., *Column-Stores vs. Row-Stores* (SIGMOD 2008) ; *The Design and Implementation of Modern Column-Oriented Database Systems* (2013).

Conclusion

- Les bases des Systèmes de Gestion de Base de Données
- Différentes optimisations naïve utilisant l'algèbre relationnelle
- Certaines optimisations dépendantes des données que notre SGBD possède
- Une analyse des résultats obtenus

But du TIPE

Description du
jeux de données

Que faire des
résultats ?

Réalisation

Ce qui est prévu

Ce qui a été fait

Optimisations mémoire

Paradigme ligne
VS colonne

Indexation des
données

Fragmentation
des données

Conclusion

Conclusion

Nos ressources

Nos ressources:

- *The Design and Implementation of Modern Column-Oriented Database Systems* 2013
- *C-Store: A Column-oriented DBMS* 2005
- *A Survey on Advancing the DBMS Query Optimizer: Cardinality Estimation, Cost Model, and Plan Enumeration* 2021
- *Extensible Query Optimizers in Practice* 2024
- *Foundation of Databases* 1995